

سؤال ١:

(٢)

$$V_k^n(s) \leftarrow (1-\alpha) V_k^n(s) + \alpha [R(s, \pi(s), s') + \gamma V^n(s')]$$

$$V(A) \leftarrow 0.9(0) + 0.1[-3 + 1(0)] = -0.1$$

$$V(B) \leftarrow 0.9(0) + 0.1[4 + 1(-0.1)] = 0.39$$

$$V(A) \leftarrow 0.9(-0.1) + 0.1[-3 + 1(0.39)] = -0.17$$

$$V(A) \leftarrow 0.9(-0.17) + 0.1[-3 + 1(0.39)] = -0.193$$

$$V(B) \leftarrow 0.9(0.39) + 0.1[4 + 1(0)] = 0.431$$

$$Q_1(A, 1) = 0.9(Q_0(A, 1)) + 0.1(-3 + \max Q(B)) =$$

$$0.9(0) + 0.1(-3 + 0) = -0.3$$

(ب)

$$Q(B, 1) = 0.9(Q_0(B, 1)) + 0.1(4 + 0) = 0.4$$

$$Q(A, 2) = 0.9(0) + 0.1(-4 + 0) = -0.4$$

$$Q_2(A, 1) = 0.9(-0.3) + 0.1(-3 + 0.4) = -(0.27 + 0.24) = -0.51$$

$$Q(B, 2) = 0.9(0) + 0.1(1 + 0) = 0.1$$

Year: _____ Month: _____ Date: _____

Subject: _____

ج) با توجه به مقدار Q_{value} و بیناکن برای هر $State$ در بار A اکشن ۲ و در B اکشن ۱ را انتخاب می‌کنیم.

د) استفاده از Q_{value} نسبت به حرکت حقایق می‌توانند (تئوری) باشند و پس از اعمال این مورد احتمالاً به حقایق (تئوری) تری برسیم.

سوال ۲: $Q_1(A, \rightarrow) = \frac{1}{2} Q_0(A, \rightarrow) + \frac{1}{2} (2 + \gamma \max_a Q_1(B, \leftarrow))$ (۱)

$Q \text{ values} = 1$

$a = 0/5 \quad = \frac{1}{2} (1) + \frac{1}{2} (2 + 0.7(-2)) = 0.5 + 0.3 = 0.8$

$Q_1(C, \leftarrow) = \frac{1}{2} Q_0(C, \leftarrow) + \frac{1}{2} (2 + 0.7(-2)) = 0.8$

$Q_1(B, \rightarrow) = \frac{1}{2} Q_0(B, \rightarrow) + \frac{1}{2} (-2 + 0.7(2)) = 0.5 - 0.3 = 0.2$

$Q_2(A, \rightarrow) = \frac{1}{2} Q_1(A, \rightarrow) + \frac{1}{2} (4 + 0.7(0)) = 2.4$

$Q(A, \rightarrow) = 2.4$

$Q(B, \rightarrow) = 0.2$

حسب وج) در این مثال ما توسط به معادله Q های برای از A به راست از B به راست و از C به چپ حرکت خواهیم کرد.

در سیاست مریضانه با توجه به مقدار Q های به دست می آوریم یک انتخاب مریضانه انجام می دهیم و اکثر صحت و صحت کنیم. اشکال اینجا است که ممکن است تخمین های ما نامناسب بودند و ما با مقادیر به این راه مریضانه نزدیکترین $reward$ و راه بیننده را نباید در حالی که اکثر کمی $explore$ نمی کردیم شاید راه های بهتری پیدا می شد.

می توان از روش $greedy$ استفاده کرد که حس را با احتمال کمی $explore$ و با مریضان راه مریضی را انتخاب می کند.

(د) الگوریتم های TD

اگر چه روشی برای مورد استفاده است و به طور پیوسته $updates$ انجام می دهد حتی در صورتی که $TD(0)$ تنها به یک قدم جلوتر نماند و برای مثال $episodic$ خواهد بود.

سؤال ۳: با استفاده از Q-Learning

$$Q_1(A, \text{Down}) = \frac{1}{2}(0) + \frac{1}{2}(2 + \frac{1}{2}(0)) = 1$$

$$Q_1(B, \text{Down}) = \frac{1}{2}(0) + \frac{1}{2}(-4 + \frac{1}{2}(0)) = -2$$

$$Q_1(B, \text{up}) = \frac{1}{2}(0) + \frac{1}{2}(0 + \frac{1}{2}(0)) = 0$$

$$Q_2(B, \text{up}) = \frac{1}{2}(0) + \frac{1}{2}(3 + \frac{1}{2}(1)) = \frac{3}{2} + \frac{1}{4} = \frac{6+1}{4} = \frac{7}{4}$$

$$Q_1(A, \text{Down}) = 1$$

$$Q_1(B, \text{up}) = \frac{1}{4}$$

$$\hat{T}(A, \text{up}, A) = \frac{1}{4}$$

$$\hat{T}(A, \text{up}, B) = 0$$

$$\hat{T}(B, \text{up}, A) = \frac{1}{2}$$

$$\hat{T}(B, \text{up}, A) = \frac{1}{2}$$

$$\hat{R}(A, \text{up}, A) = -1$$

$$\hat{R}(A, \text{up}, B) = 0$$

$$\hat{R}(B, \text{up}, A) = 3$$

$$\hat{R}(B, \text{up}, B) = 0$$

با توجه به مقدارهای فوق، هر کدام از شرایط \hat{T} و \hat{R} که دست آمده، جایگزین کنیم از جدول اول، که

$R = -1$ (سوال ۴)

$$V^n(15) = E_{T1} \{ r_{t+1} + V^n(s_{t+1}) \mid s_t = S \}$$

$$= -1 + \frac{1}{4} V^n(12) + \frac{1}{4} V^n(13) + \frac{1}{4} V^n(14) + \frac{1}{4} V^n(15)$$

$$= -1 - \frac{1}{4} \times 22 - \frac{1}{4} \times 20 - \frac{1}{4} \times 14 - \frac{1}{4} V^n(15)$$

$$\frac{3}{4} V^n(15) = -15 \Rightarrow V^n(15) = -20$$

سؤال ۵:

۱) Exploration یک راه سودمند در بلندمدت است که به agent اجازه می‌دهد که دانش را در مورد action

هایی که در طولانی مدت به سود می‌انجامد بیترکند.

در مقابل Exploitation از ارزش تخصیص فعلی Agent استفاده کرده و راه حل سریع را انتخاب می‌کند. به بیشترین reward دست پیدا کند. اما نگاهی که Agent تخصیص های سریعانه می‌زند و واقعی نیست ممکنه بیشترین reward و بهترین راه نباشد.

ب) با گذر دادن مقدار ϵ در ϵ -greedy الگوریتم وسیله‌ای داریم آن به مغز به نوعی صبر یا احتمال explore کردن را کم می‌کنیم و به الگوریتم greedy نزدیک‌تر می‌شویم که خیلی ایده‌ی منتهی به

(>) تابع Value V برای اندازه گیری میزان خوب بودن یک state خاص از نظر پاداش کلی سود دانهنگار برای
 agent است که طبق یک Policy عملی کند و استفاده می شود و V^* حداکثر مقدار قابل دسترس
 را برای هر حالت در فضا حالت داده می شود به جای دیگر
 در حالت Q Value به نشان می دهد که یک عمل خاص با توجه به وضعیت برای عامل که از یک
 Policy پیروی کند چه قدر خوب است. تابع Q حداکثر بازده قابل دستیابی از یک جهت حالت
 کل یعنی توسط خاموشی به حساب می آید.
 Q-value ها برای دستیابی به ^{function} transition در دسترس نیستند (مثل نوی) اما در حالتی که Action space زیاد
 داریم این Q ما ضعیف را امتیاز می دهد برای استفاده.
 اکثر transition function در این گامی اوقات استفاده است.